Module 1 Python 程序、类与函数说明

本文档对应 Code_git/Module_1 的当前代码。它按文件说明每个类和函数的职责、输入和输出。

约定：

- self 是实例方法自动接收的当前对象，cls 是类方法自动接收的当前类；调用时通常不需要手动传入。
- 名称以 _ 开头的函数或方法是模块内部实现，不建议下游程序直接调用。
- None 表示函数没有业务返回值；它可能完成校验、写文件或修改初始化中的对象状态。
- Mapping 可理解为字典型对象，Sequence 是有顺序的集合，Iterable 是可逐项遍历的对象。

1. 文件总览

文件	主要职责
iiif_provider_census/models.py	定义统一数据模型、URL 规范化和稳定 ID
iiif_provider_census/fetch.py	从 HTTP(S)、file URI 或本地路径读取 JSON
iiif_provider_census/registry.py	解析 Registry、人工清单和目录快照，生成统一记录
iiif_provider_census/selector.py	根据明确条件筛选本次运行的机构入口
iiif_provider_census/store.py	读写 JSONL、CSV 和 TXT 日志
iiif_provider_census/pipeline.py	编排完整的模块 1 工作流
iiif_provider_census/cli.py	定义命令行参数和执行入口
iiif_provider_census/__init__.py	暴露包的公共类、函数和版本号
iiif_provider_census/__main__.py	支持 python -m iiif_provider_census
tools/build_catalog_inputs.py	将两份外部目录转换成本地 JSON 输入快照
tests/test_selector_and_store.py	测试筛选和文件存储
tests/test_registry.py	测试 Registry/人工清单解析
tests/test_pipeline.py	测试完整流水线
tests/test_catalog_builder.py	测试外部目录转换工具

2. models.py

2.1 普通函数

canonicalize_url(value)

项目	说明
用途	校验并规范化 HTTP(S) URL；统一协议和主机名大小写、删除默认端口和 fragment
输入	value: str，待处理 URL
输出	str，规范化后的 URL；非法 URL 或带账号密码时抛出 ValueError

stable_provider_id(discovery_endpoint)

项目	说明
用途	根据规范化入口生成可重复的机构记录 ID
输入	discovery_endpoint: str
输出	str，格式为 provider- 加 SHA-256 摘要前 16 位

_optional_string(value)

项目	说明
用途	把可选值转换成去除首尾空白的文本
输入	value: Any
输出	非空时返回 str；缺失或空文本返回 None

2.2 SourceProvenance 类

用途：保存一条记录的来源证据。

构造输入：

字段	类型	含义
source_type	str	来源类别，例如 iiif_registry
source_url	str	公开来源 URL 或本地来源路径
source_page_url	Optional[str]	具体条目所在页面
activity_type	Optional[str]	Registry 活动类型，例如 Update
observed_at	Optional[str]	本次观察时间

构造输出：一个不可变的 SourceProvenance 实例。

SourceProvenance.from_mapping(value)

项目	说明
用途	从 JSON 解码后的字典重建来源对象
输入	value: Mapping[str, Any]
输出	SourceProvenance 实例

2.3 ProviderRecord 类

用途：表示模块 1 中一条统一的机构或入口记录。

主要构造输入：

字段	类型	含义
provider_id	str	稳定记录 ID
name	str	机构、馆藏或实现名称
institution_url	Optional[str]	面向人的机构页面
discovery_endpoint	str	交给下一模块检查的入口
discovery_type	str	OrderedCollection、InstitutionWebsite 等入口类型
stream_label	Optional[str]	入口说明
collection_focus	Optional[str]	馆藏范围
estimated_size	Optional[int]	已知时的预计规模
rights_status	str	unknown、declared 或 mixed
rights_values	tuple[str, ...]	来源级版权值
record_status	str	active 或 removed
last_checked_at	Optional[str]	最近检查时间
source	SourceProvenance	来源证据
raw_source_record	Mapping[str, Any]	未丢失的原始来源记录
schema_version	str	模块 1 记录模式版本

构造输出：经过校验、不可变的 ProviderRecord 实例。

__post_init__()

项目	说明
用途	创建对象后自动规范化 URL，并检查名称、规模和状态
输入	隐式输入当前实例
输出	None；非法字段抛出 ValueError

to_dict()

项目	说明
用途	转换为可被 json 写出的普通字典
输入	隐式输入当前实例
输出	dict[str, Any]

ProviderRecord.from_mapping(value)

项目	说明
用途	从 JSONL 字典校验并重建记录
输入	value: Mapping[str, Any]
输出	ProviderRecord 实例；缺失或非法字段会报错

3. fetch.py

3.1 FetchError 类

用途：表示 JSON 来源无法读取、下载或解析。它继承 RuntimeError。

- 输入：通常是错误说明字符串。
- 输出：FetchError 异常对象；被 raise 后中断当前读取流程，由上层处理。

3.2 JsonFetcher 类

用途：统一执行本地和远程 JSON 读取，并限制超时与重试。

__init__(timeout_seconds=20.0, retries=2)

项目	说明
用途	创建读取器并检查网络参数
输入	正数超时秒数；非负重试次数
输出	JsonFetcher 实例；参数非法时抛出 ValueError

load(reference)

项目	说明
用途	根据地址类型读取 JSON
输入	reference: str，HTTP(S) URL、file URI 或本地路径
输出	Any，json 解码后的字典、数组等对象；失败抛出 FetchError

_load_http(url)

项目	说明
用途	发送带请求头的 HTTP GET，并进行有限重试和短暂指数退避
输入	url: str
输出	解码后的 JSON 对象；所有尝试失败后抛出 FetchError

注意：JsonFetcher 只证明“某个来源能否作为 JSON 被读取”，并不执行模块 2 所需的完整入口有效性检查。

4. registry.py

utc_now()

项目	说明
用途	生成无微秒的当前 UTC 时间
输入	无
输出	`str`，例如 `2026-09-17T10:00:00Z`

`read_registry(source, fetcher, max_pages=100, observed_at=None)`

项目	说明
用途	读取 Registry Collection/Page，沿 `first/next` 或 `last/prev` 遍历，解析活动并去重
输入	来源地址、`JsonFetcher`、最大分页数、可选观察时间
输出	`list[ProviderRecord]`；结构不支持、分页循环或超过限制时抛出错误

`read_manual_records(source, fetcher, observed_at=None)`

项目	说明
用途	读取人工清单或生成的目录快照，保留来源信息并统一成记录
输入	来源地址、`JsonFetcher`、可选观察时间
输出	去重后的 `list[ProviderRecord]`

`deduplicate_records(records)`

项目	说明
用途	按规范化 `discovery_endpoint` 去重并按名称、入口排序
输入	`Iterable[ProviderRecord]`
输出	`list[ProviderRecord]`；同一入口保留最后出现的记录

`_record_from_activity(activity, source_url, page_url, observed_at)`

项目	说明
用途	把一条 Add/Create/Update/Delete/Remove 活动转换成记录
输入	活动字典及来源上下文
输出	有效时返回 `ProviderRecord`；无关或缺少必要信息时返回 `None`

`_parse_legacy_registry_record(document, source, observed_at)`

项目	说明
用途	兼容旧式带 `streams` 数组的 Registry 文件
输入	Registry 字典、来源地址、观察时间
输出	`list[ProviderRecord]`

`_extract_label(value)`

项目	说明
用途	从 `label`、`name`、`nameMap`、`summary` 或语言映射中找名称
输入	`Mapping[str, Any]`
输出	`str` 或 `None`

_language_value(value)

项目	说明
用途	递归提取字符串、数组或语言映射中的第一个非空文本
输入	Any
输出	str 或 None

_rights_values(value)

项目	说明
用途	统一单个或多个版权值
输入	Any
输出	tuple[str, ...]

_as_mapping_list(value)

项目	说明
用途	把一个字典或字典数组统一为列表
输入	Any
输出	list[Mapping[str, Any]]

_link_id(value)

项目	说明
用途	从 URI 字符串或含 id/@id 的对象读取链接
输入	Any
输出	str 或 None

_resolve_reference(base, reference)

项目	说明
用途	解析远程或本地相对链接
输入	基准地址与引用地址
输出	str，解析后的绝对 URL 或绝对本地路径

_host_name(url)

项目	说明
用途	从 URL 提取主机名作为后备名称
输入	url: str
输出	str，主机名；无法解析时返回原 URL

_optional_text(value)

项目	说明
用途	转换可选文本并去除空白
输入	Any
输出	str 或 None

5. selector.py

5.1 SelectionCriteria 类

用途：保存筛选规则。

构造输入：include_provider_ids、include_exact_names、include_name_keywords、include_hosts、exclude_name_keywords、exclude_hosts、record_statuses 等字符串元组，以及可选正整数 limit。

构造输出：不可变的 SelectionCriteria 实例。

__post_init__()

项目	说明
用途	确保 limit 为 None 或正数
输入	隐式输入当前实例
输出	None；0 或负数抛出 ValueError

SelectionCriteria.from_mapping(value)

项目	说明
用途	从 JSON 配置字典创建筛选条件
输入	value: Mapping[str, Any]
输出	SelectionCriteria 实例

5.2 普通函数

select_providers(records, criteria)

项目	说明
用途	筛选、稳定排序，并应用数量上限
输入	记录可迭代对象和 SelectionCriteria
输出	list[ProviderRecord]

_matches(record, criteria)

项目	说明
用途	判断单条记录是否满足所有包含、排除和状态条件
输入	一个 ProviderRecord 和筛选条件
输出	bool

_host_matches(host, rule)

项目	说明
用途	匹配指定域名本身或其子域名
输入	实际主机名和域名规则
输出	bool

_strings(value)

项目	说明
用途	校验选择配置中的数组并清理空元素
输入	Any，必须为列表或 None
输出	tuple[str, ...]；类型错误抛出 ValueError

6. store.py

write_jsonl(path, records)

项目	说明
用途	每行写入一条完整 JSON 机构记录
输入	输出 Path；记录可迭代对象
输出	int，实际写入条数

read_jsonl(path)

项目	说明
用途	逐行解析并校验 JSONL
输入	输入 Path
输出	list[ProviderRecord]；某行非法时报告文件与行号

write_csv(path, records)

项目	说明
用途	写入带 UTF-8 BOM 的人工查看表
输入	输出 Path；记录可迭代对象
输出	int，实际写入条数

write_text(path, value)

项目	说明
用途	写入 UTF-8 文本并保证末尾有换行
输入	输出 Path；文本字符串
输出	None

_csv_row(record)

项目	说明
用途	将嵌套记录压平为 CSV 字段字典
输入	ProviderRecord
输出	dict[str, Any]

CSV_COLUMNS 是常量，不是函数；它规定 CSV 列名及顺序。

7. pipeline.py

7.1 PipelineResult 类

用途：表示一次成功完成的模块 1 运行结果。

构造输入：

- all_provider_count: int
- selected_provider_count: int
- output_directory: Path
- all_providers_jsonl: Path
- selected_providers_jsonl: Path
- providers_csv: Path
- log_txt: Path

构造输出：不可变的 PipelineResult 实例。它表示运行统计与文件位置，不代表模块 2 已经验证这些入口。

7.2 函数

`run_pipeline(config_path, institution_selection, run_time=None)`

项目	说明
用途	执行配置读取、来源加载、统一去重、人工选择、文件写出和日志生成
输入	配置路径；机构名称序列；可选运行时间
输出	`PipelineResult`

`_local_run_time(value)`

项目	说明
用途	确保运行时间带本机时区
输入	`Optional[datetime]`
输出	带时区的 `datetime`

`_selection_for_run(institution_selection)`

项目	说明
用途	将 `--institution` 值转换成正式筛选规则
输入	`Sequence[str]`
输出	三元组：`SelectionCriteria`、日志标签、需验证的名称元组

`_validate_requested_names(requested_names, all_records, selected_records)`

项目	说明
用途	防止拼写错误或 inactive 名称被静默忽略
输入	请求名称、完整记录、选中记录
输出	`None`；有缺失名称时抛出 `ValueError`

`_format_run_log(...)`

项目	说明
用途	组合人类可读的运行日志
输入	时间、选择标签、来源报告、计数和三个输出路径
输出	`str`

`_read_config(path)`

项目	说明
用途	读取配置 JSON 并检查顶层对象
输入	`Path`
输出	`Mapping[str, Any]`；读取或解析失败时抛出 `ValueError`

`_mapping(value, name)`

项目	说明
用途	校验一个值是否为字典型对象
输入	任意值及其错误提示名称
输出	`Mapping[str, Any]`；类型错误时抛出 `ValueError`

_source_list(value, name)

项目	说明
用途	校验来源配置是否为数组
输入	任意值及配置项名称
输出	`list[str]`

_resolve_local_source(source, base_directory)

项目	说明
用途	远程 URL 保持不变；本地相对路径转为绝对路径
输入	来源字符串和配置目录
输出	`str`

_resolve_directory(value, base_directory)

项目	说明
用途	解析输出或日志目录
输入	路径字符串和配置目录
输出	绝对 `Path`

8. cli.py

build_parser()

项目	说明
用途	定义 `run`、`select` 以及所有命令行参数
输入	无
输出	`argparse.ArgumentParser`

main(argv=None)

项目	说明
用途	解析命令；执行完整流水线或已有目录的再次筛选；输出 JSON 摘要
输入	可选字符串参数列表；None 时使用真实命令行
输出	成功返回 `0`；已处理错误打印到 stderr 并返回 `1`

`run` 子命令需要 `--config` 和一个或多个 `--institution`。`select` 子命令需要已有 JSONL、输出路径和筛选条件 JSON。

9. __init__.py 与 __main__.py

这两个文件没有自定义函数或类：

- `__init__.py` 重新导出 `ProviderRecord`、`SourceProvenance`、`PipelineResult`、`SelectionCriteria`、`run_pipeline` 和 `select_providers`，并定义版本 `0.1.0`。
- `__main__.py` 导入并执行 `cli.main()`，把返回值作为进程退出码。因此可以运行 `python -m iiif_provider_census ...`。

10. tools/build_catalog_inputs.py

_front_matter(path)

项目	说明
用途	读取 Guide 页面开头简单 YAML 中的标量字段
输入	Markdown 文件 `Path`
输出	`dict[str, str]`；无合法 front matter 时为空字典

`_git_revision(repository)`

项目	说明
用途	调用本机 Git 获取来源仓库当前提交
输入	仓库 `Path`
输出	提交哈希 `str`；失败返回 None

`build_guides_records(repository)`

项目	说明
用途	提取所有可见且有 homepage 的官方 Guide 条目
输入	IIIF Guides 仓库路径
输出	按名称排序的 `list[dict[str, object]]`

`build_awesome_records(repository)`

项目	说明
用途	提取 `implementations.md` 每个一级 Markdown 条目
输入	Awesome IIIF 仓库路径
输出	按名称排序的候选字典列表

`_write_catalog(path, source_type, source_url, source_revision, providers)`

项目	说明
用途	保存来源元数据和候选记录
输入	输出路径、来源字段、记录可迭代对象
输出	`int`，写入的记录数量

`build_parser()`

项目	说明
用途	定义两个来源仓库路径和输出目录参数
输入	无
输出	`argparse.ArgumentParser`

`main()`

项目	说明
用途	构建两份目录快照并打印数量 JSON
输入	参数来自命令行
输出	成功返回整数退出码 `0`

这个工具只准备输入文件，不进行网络可访问性或 IIIF 合规性检查。

11. 测试文件中的类和函数

所有测试方法都由 unittest 调用：显式业务输入为空，隐式输入为 self；正常输出为 None，断言失败时抛出 AssertionError。

11.1 tests/test_selector_and_store.py

provider(name, endpoint, status="active")

项目	说明
用途	为测试快速创建最小机构记录
输入	名称、入口、可选状态
输出	ProviderRecord

SelectorAndStoreTests

项目	说明
用途	汇集筛选和存储测试
输入	由 unittest 创建
输出	测试用例实例

test_filters_by_name_host_status_and_limit_deterministically()

项目	说明
用途	验证域名、排除词、状态和 limit 的组合
输入	仅隐式 self
输出	None

test_exact_name_matching_is_case_insensitive()

项目	说明
用途	验证完整名称匹配不区分大小写
输入	仅隐式 self
输出	None

test_jsonl_round_trip_preserves_raw_record_and_csv_is_flat()

项目	说明
用途	验证 JSONL 保留嵌套来源而 CSV 为扁平视图
输入	仅隐式 self
输出	None

11.2 tests/test_registry.py

RegistryReaderTests

项目	说明
用途	汇集 Registry 解析测试
输入	由 unittest 创建
输出	测试用例实例

setUp()

项目	说明
用途	每个测试前建立读取器和固定时间
输入	隐式 `self`
输出	`None`，设置两个实例属性

`test_follows_pages_and_keeps_latest_activity_per_endpoint()`

项目	说明
用途	验证正向分页和较新活动覆盖旧活动
输入	隐式 `self`
输出	`None`

`test_live_registry_actor_shape_and_declared_rights_are_parsed()`

项目	说明
用途	验证当前 Registry actor 与 rights 结构
输入	隐式 `self`
输出	`None`

`test_can_traverse_backwards_when_registry_omits_first_page()`

项目	说明
用途	验证只有 `last/prev` 时可反向读取并恢复时间顺序
输入	隐式 `self`
输出	`None`

`test_reads_manual_provider_list()`

项目	说明
用途	验证人工清单可被统一
输入	隐式 `self`
输出	`None`

`test_manual_catalog_preserves_external_provenance()`

项目	说明
用途	验证生成目录的公开来源和条目页不会丢失
输入	隐式 `self`
输出	`None`

11.3 `tests/test_pipeline.py`

`PipelineTests`

项目	说明
用途	汇集完整流水线测试
输入	由 `unittest` 创建
输出	测试用例实例

test_local_end_to_end_run_writes_contract_outputs()

项目	说明
用途	验证本地完整执行会写出 JSONL、CSV 和秒级日志
输入	隐式 `self`
输出	`None`

test_all_selects_every_active_known_provider()

项目	说明
用途	验证 `all` 选择所有 active 记录
输入	隐式 `self`
输出	`None`

test_unknown_explicit_institution_fails_with_available_names()

项目	说明
用途	验证未知机构会明确报错并显示可用名称
输入	隐式 `self`
输出	`None`

11.4 tests/test_catalog_builder.py

CatalogBuilderTests

项目	说明
用途	汇集外部目录转换测试
输入	由 `unittest` 创建
输出	测试用例实例

test_guides_excludes_hidden_and_non_resource_pages()

项目	说明
用途	验证隐藏或没有 homepage 的 Guide 页面不会成为候选记录
输入	隐式 `self`
输出	`None`

test_awesome_keeps_every_list_entry()

项目	说明
用途	验证 Awesome IIIF 的项目或工具条目不会被静默删除
输入	隐式 `self`
输出	`None`

12. 一次实际运行中的调用关系

```
__main__.py
  -> cli.main()
     -> cli.build_parser()
     -> pipeline.run_pipeline()
        -> pipeline._read_config()
        -> JsonFetcher(...)
        -> registry.read_registry()
```

```
   -> JsonFetcher.load()
   -> registry._record_from_activity()
-> registry.read_manual_records()
-> registry.deduplicate_records()
-> pipeline._selection_for_run()
-> selector.select_providers()
   -> selector._matches()
-> pipeline._validate_requested_names()
-> store.write_jsonl()
-> store.write_csv()
-> pipeline._format_run_log()
-> store.write_text()
-> PipelineResult
```

这条调用链说明：pipeline.py 负责编排，实际读取、解析、筛选和保存分别由专门文件完成。